语音交互需求-20260430

1. 文档基础信息

- **模块名称**：语音交互模块
- **所属产品**：Loona Deskmate App / Loona Deskmate 设备侧能力
- **文档类型**：正式需求文档
- **目标读者**：产品、设计、客户端、设备侧、算法、服务端、测试
- **关联模块**：注意力模块、环境感知模块、状态管理模块、决策机模块、Agent 核心能力系统、具身能力模块、多模态交互模块

2. 变更日志

版本	变更内容	变更人	变更时间
经销商demo版本	完整规范需求	程楠	3月25日
正式交付版	无更新需求，需持续优化，选取更优服务api。	程楠	4月1日

3. 模块背景与目标

3.1 背景

Loona Deskmate 作为面向个人桌面办公场景的 Embodied Agent 智能硬件产品，语音交互是用户与 Loona 建立持续关系、发起交流、获取回应、感知陪伴感的核心入口之一。

对于桌面办公场景而言，用户并不总是处于“拿起手机操作”或“盯着屏幕输入”的状态。很多高频交互天然更适合通过语音完成，例如快速唤起 Loona、发起一句话请求、在工作中低打扰地进行自然交流，以及在不方便操作手机或电脑时完成基础互动。

因此，语音交互模块不只是“语音识别 + 语音播报”，而是一个覆盖**唤醒、判停、ASR、TTS**的基础语音能力模块，负责承接用户从开口到听到回复的核心语音链路，并支撑 Loona 在桌面场景中的自然交流体验。

其中，与 Agent 决策、任务执行状态同步、执行过程反馈、结果反馈、完整打断与排队控制相关的能力，**不属于本模块范围**，由决策机等相关模块承接。

3.2 Loona自然语音互动的目标

3.2.1 目标：

人与Loona用语言交流像人与人、人与宠物之交流一样，自然流畅

3.2.2 一个流畅的对话过程的步骤拆解：

1. A产生了想通话的意图
   a. 声音、音源、眼神、唇动的多模态判断，（后期可能结合语义）
2. B及时感知到这个意图，并给出明确的且平和的在听信号（你说）
3. A开始说话，在这个过程中可能会有一些组织语言或思索产生的停顿
4. B知道A讲完了，B充分理解A所要表达的意思
5. B给出积极的、合理的反馈
6. B在给出反馈后知道自己需要继续等待A的回答还是去做别的事。

3.2.3 整个交互流程的关键要素：

1. B知道什么时候需要去听并给出在听信号
2. B知道A什么时候说完了，需要去理解
3. B能正确理解A的语音意图，并给出合理反馈
4. B知道什么时候要结束对话，什么时候要继续对话

3.2.4 Loona在与用户语音互动过程中需要做到：

如果把以上流程映射到用户与Loona的语音互动上，Loona需要做到：

1. 知道什么时候人要对她说、人正在对她说，主动去听
2. 耐心等待，充分知道人已经说完，在等待Loona反馈
3. 充分理解人的意图｜意思
4. 在理解的基础上给出合理的反馈
5. 根据之前的语音互动判断需不需要继续对话，还是结束对话，进入其他互动

3.3 模块目标

本模块的核心目标包括：

1. 为用户提供**稳定、低误触发、可持续使用**的语音唤醒能力；
2. 为用户提供**准确、可理解、低截断率**的语音输入承接能力；
3. 为 Agent 提供**清晰、结构化、可继续调度**的语音转文本输入；
4. 为用户提供**具备 Loona 角色感的情感化语音输出**，并结合表情、动作进行一致表达；

5. 支持在 **Loona 播报 / 响应过程中被用户打断**，避免用户需要被动等待，保证基础语音交互链路的自然性；
6. 支持在 **用户误打断或系统误判打断后，Loona 能进行合理的恢复播报和响应**，避免对话链路中断后直接悬空，保证交互连续性与可理解性。

4. 功能范围

4.1 当前需求范围

本模块当前纳入正式需求范围的能力包括：

- 语音唤醒；
- 唤醒后的监听承接；
- 判停；
- ASR 识别；
- ASR 结果传递给后续 Agent / 决策链路；
- TTS 播报；
- TTS 与 Loona 表情、动作联动的情感化表达；
- Loona 播报 / 恢复响应过程中用户打断的基础支持；
- 支持用户误打断后Loona的恢复播报。
- 唤醒失败、误唤醒、音频截断、识别失败、播报异常等问题的处理要求。

4.2 当前需求外范围

以下能力与语音交互强相关，但不在本需求中定义：

- Agent 任务规划与决策逻辑；
- 执行过程反馈；
- 任务结果反馈；
- 完整的打断、抢占、排队与多任务调度机制；
- 外部工具调用状态反馈；
- 长任务等待中的系统状态表达；

上述内容由**决策机模块**及相关模块负责定义。

5. 用户故事

- 作为用户，我希望直接通过一句话叫起 Loona，而不是每次都手动操作设备或 App。

- 作为用户，我希望 Loona 在我唤醒后能够稳定接住我说的话，不要首句被吞或中途截断。
- 作为用户，我希望 Loona 不要轻易被远处人声、背景音频或无意图发言误唤醒。
- 作为用户，我希望 Loona 能较准确地听懂我说的话，并把它正确传递给后续 Agent 处理。
- 作为用户，我希望 Loona 的语音回应不是机械播报，而是有角色感、情绪感，并能结合表情和动作表达。
- 作为用户，我希望当 Loona 正在播报或响应时，我可以再次开口打断它，而不是只能被动等它说完。

6. 功能流程总览

本模块整体链路如下：

持续语音唤醒听 → 识别唤醒 → 承接用户语音输入 → 判停 → ASR → 文本传递至后续 Agent / 决策链路 → TTS 返回语音播报 → 表情/动作联动

其中：

- **唤醒**负责决定是否进入本轮语音链路；
- **判停**负责决定用户一轮输入何时结束；
- **ASR**负责将用户语音转为文本；
- **TTS**负责将返回内容转为语音；
- **表情/动作联动**负责让 Loona 的语音输出更具角色感；
- **可打断**仅指 Loona 在播报 / 响应过程中，允许用户重新开口并中断当前播报。
- 误打断恢复指**用户误打断或系统误判打断后，Loona 能进行合理的恢复播报和响应**详细需求。

7. 子模块功能

7.1 语音唤醒

7.1.1 能力定义

语音唤醒用于让 Loona 在持续语音监听状态下识别用户是否发起当前轮语音交互，并在识别到有效唤醒意图后进入本轮语音承接状态。

7.1.2 产品要求

1. 系统需支持结合多模态信息，对用户是否存在明确语音交互意图进行判断；对于满足条件的场景，不依赖固定唤醒词直接进入当前轮语音承接状态；
2. 系统识别到有效唤醒后，应立即进入当前轮语音承接状态，稳定接收用户后续输入，并确保唤醒识别与正文承接之间的语音内容尽量不丢失、不截断；

3. 系统进入当前轮语音交互状态后，Loona 需给出明确反馈，反馈方式可包括但不限于：
    a. 表情反馈；
    b. 动作反馈；
    c. 简短语音反馈；
    d. 状态或界面反馈；
4. 连续多次触发唤醒时，系统应避免重复进入混乱状态；
5. 唤醒模块需与注意力模块、环境感知模块联动，在可行情况下综合当前声源位置、距离、朝向及上下文状态优化唤醒判断。

7.1.3 重点问题关注

重点问题包括：

- **误唤醒**：远处人声、背景对话、电视音频、非交互对象发言导致 Loona 被误唤醒；
- **唤不醒**：用户明确对 Loona 说话，但系统未成功进入监听状态；
- **音频流截断**：唤醒到监听的切换过程中，用户语音前段被截断；
- **短句承接不稳定**：用户唤醒后直接说极短命令，系统未能稳定接住。

7.2 判停

7.2.1 能力定义

判停用于判断用户一轮语音输入是否结束，并决定何时将本段音频送入 ASR 处理。

7.2.2 产品要求

1. 系统需在用户自然说完后较快完成判停，不应造成明显等待感；
2. 判停完成后，系统应立即进入**解析状态**，并通过明确、可感知的反馈让用户知道当前轮输入已结束、系统正在处理，如无额外补充无需继续讲话；
3. 系统应重点优化唤醒后首句、连续短句、自然口语停顿等场景下的判停准确性；
4. 在用户长句表达过程中，若判停错误导致语句切断，应尽量减少对后续理解的影响；
    a. 对于刚进入解析流程后短时间内出现的同轮补充输入，系统应支持按同一轮语音输入继续承接，并合并进入后续 ASR 处理，避免用户一句话被机械切成多轮多次解析；
5. 判停结果需与音频流管理一致，避免出现“用户还在说，系统已结束录入”或“用户已说完，系统迟迟不进入识别”的情况。
6. 支持在判停后端侧对当前轮语音是否属于用户真实唤醒 / 对话意图进行一次非语义理解层面的基础判断，对于判定为**误唤醒**或**明显无效输入**的语音片段，系统可直接丢弃，不进入后续上传与处理流程，以减少无效内容对后续链路的干扰；

7.2.3 重点问题关注

重点问题包括：

- 判停后语音有效性过滤机制需重点控制误判风险，避免将用户真实输入错误识别为无效内容而不上传，导致内容丢失；
  - 该场景下因误判导致的有效内容丢失率应控制在 **3% 以内**。

7.3 ASR

7.3.1 能力定义

ASR 模块负责将用户语音稳定转写为文本结果，供后续 Agent / 决策链路进行理解与处理。

其核心职责是尽可能准确、及时、稳定地完成语音转文本，并为后续链路提供可用、规范的输入结果。

7.3.2 产品要求

1. **方案选型与持续优化**
   - 系统需基于现有方向持续进行 ASR 能力优化迭代，在多个候选 ASR API 中选择综合效果最优方案；同时需持续关注并测试新出现的 ASR API，从准确度、时延、稳定性、异常率等维度综合评估，确保当前使用方案在现阶段具备整体最优表现；
   - 自研 ASR 模型需持续开展探索，并形成阶段性结论与最终总结，用于支持后续能力路线判断；
   - 方案评估不得仅依据单轮转写文本效果，还需结合时延、稳定性、异常率等指标进行综合判断；
2. ASR 输出需为后续 Agent 提供标准化文本结果；
3. 当识别质量较低时，系统需支持对低置信度结果进行丢弃，并保证整体流程不被卡死；
4. 当 ASR 失败时，系统不得出现无响应状态，应具备基础异常收口能力；
5. ASR 处理时延目标应低于 **200ms**。

7.3.3 异常处理要求

以下情况需定义明确处理方式：

- **识别为空**：走误打断处理逻辑；
- **识别结果明显异常、置信度低或不可解析**：走误打断处理逻辑；
- **网络异常或 API 调用失败**：走网络错误提示逻辑；
- **时延过长导致用户等待感明显**：走超时提示逻辑；
- **首尾字频繁缺失导致语义不完整**：需纳入重点问题持续优化，并在必要时按异常识别结果进行收口处理。

7.3.4 重点问题关注

ASR 需重点优化以下场景：

- 短句命令识别；
- 桌面办公场景下的自然口语表达；
- 多语言夹杂表达；
- 专有名词、人名、产品名、应用名识别。

ASR 需重点关注以下问题：

- 识别准确率；
- 首字丢失、末字丢失及中间字丢失问题；
- 错误将用户语音转录为其他语言的问题。
- 短句场景下识别鲁棒性不足，易将不同输入误识别为固定高频词或固定短语。

7.4 TTS 语音合成与语音回复

7.4.1 能力定义

TTS 模块负责将系统生成的回复内容转化为语音输出，并承接 Loona 对外声音表达的核心职责，是 Loona 角色人格、情绪传达与具身反馈的重要组成部分。

7.4.2 核心目标

TTS 不只是将文本“念出来”，而是需要承接 Loona 的角色表达，使用户感受到：

- Loona 是在自然回应用户，而非机械播报；
- Loona 的表达具有明确的情绪感和角色感；
- Loona 的语音、文本、表情、动作与角色设定保持一致；
- Loona 的播报过程可自然融入实时交互，而非割裂地单独输出。

7.4.3 产品要求

1. **基础播报能力**
    - TTS 需具备稳定、清晰、自然的基础语音播报能力。
    - 发音需准确，语音需连续，不应频繁出现卡顿、中断、爆音、呲音等明显问题。
2. **方案选型与持续优化**
    - 系统需基于现有方向持续进行 TTS 能力优化迭代，在多个候选 TTS API 中选择综合效果最优方案。

- 需持续关注并测试新出现的 TTS API，从自然度、时延、稳定性、异常率、音色匹配度等维度进行综合评估，确保当前使用方案在现阶段具备整体最优表现。
- 除基础播报效果外，还需重点考虑音色与 Loona 角色设定的一致性。
- 自研 TTS 模型需持续开展探索，并形成阶段性结论与最终总结，为后续技术路线和产品能力演进提供依据。
- TTS 方案评估不得仅依据单轮文本播报效果进行判断，还需结合时延、稳定性、异常率、情绪匹配度、角色一致性等指标进行综合评估。

3. **语音与文本同步**
   - TTS 播报内容应与对应回复文本保持一致。
   - 语音播放时，客户端应同步展示对应文本内容，避免语音与文本显示脱节或明显不同步。
4. **多模态联动要求**
   - TTS 需支持与 Loona 的表情、动作、朝向等能力联动执行。
   - 语音表达、表情动作和角色状态需保持较高一致性，不应出现明显割裂感。
5. **语气与情绪匹配**
   - TTS 的语气、节奏和情绪表达需与文本语义及情绪标签保持一致，不得出现明显情绪错配。
   - 对不同回复场景，需支持相应的语气变化，如安抚、调皮、思考、惊讶等。
6. **可打断能力**
   - 在 Loona 恢复播报或恢复响应阶段，TTS 播报需支持被用户再次开口打断，并及时停止当前播报，进入新一轮输入处理流程。
   - 在判定为误打断后，中止的语音播报应具备恢复播报能力。
7. **时延要求**
   - TTS 端到端播报启动时延目标应控制在 1 秒以内。
   - 对不同长度文本，可结合实际场景对时延目标进行分层优化，但整体需保证用户感知自然、响应及时。

7.4.4 重点问题关注

1. TTS 无法稳定返回，导致声音卡顿、中断或播报失败；
2. 语音内容与文本显示不同步；
3. 语音表达与表情、动作、朝向不匹配；
4. TTS 出现呲音、爆破音等明显音频质量问题。

7.5 播放过程中的用户打断和误打断

7.5.1 能力定义

本模块支持一种轻量的打断与恢复能力：
当 Loona 处于**播报 / 响应**过程中时，用户可再次开口，通过新的语音输入打断当前恢复播报，并重新进入新一轮语音承接流程。
同时，当出现**用户误打断**或**系统误判为被打断**的情况时，Loona 需支持在合适时机继续进行恢复播报，以保证当前轮语音输出具备基本连续性。

7.5.2 核心目标

- 让用户在 Loona 恢复播报 / 恢复响应过程中可以重新开口并打断当前播报；
- 降低“必须等 Loona 说完才能继续”的卡顿感；
- 使基础语音交互链路更自然、更符合真实对话习惯。

7.5.3 产品要求

1. 该打断能力仅适用于 **Loona 播报 / 响应阶段**；
2. 用户重新开口后，系统应优先停止当前恢复播报，并重新进入监听；
3. 打断后的后续任务如何处理、是否覆盖原任务、是否排队，不在本模块中定义；
4. 若当前不处于可打断的恢复阶段，则由后续决策机模块定义是否允许打断，本模块不负责完整判定；
5. 当检测到**用户误打断或系统误判打断**时，例如用户无明确新意图、噪声误触发、系统错误地将环境声、短噪音、无效片段识别为用户打断等，系统应支持继续原有恢复播报；
6. 恢复播报应尽量自然，不应让用户感知到明显“断裂后重启”的生硬体验；
7. 恢复播报不要求逐字从断点精确续播，但需保证语义连续、用户可理解当前回复仍在继续。
    a. 可接受从下一句开始播放。

8. 重点场景说明

8.1 无唤醒词直接承接场景

用户未明确说出固定唤醒词，但系统结合多模态信息判断其存在明确语音交互意图，并直接进入当前轮语音承接状态。

此类场景要求：

- 多模态意图判断需尽量准确，避免无明确意图时误进入语音链路；
- 进入承接状态后，用户后续输入需被稳定接收；
- 承接过程中的前段语音内容尽量不丢失、不截断；

- Loona 需通过表情、动作、简短语音或状态反馈，让用户明确感知系统已开始响应。

8.2 唤醒后立即说短句场景

系统识别唤醒，用户直接说出短句、极短命令或简短问题。

此类场景要求：

- 唤醒识别前内容与正式进入舰艇状态承接内容之间衔接自然，避免首句被吞；
- 判停对短句场景需保持较高准确性，避免过早结束或误切分；
- ASR 对短句需具备更高稳定性，避免频繁误识别为固定高频词或固定短语；
- 整体链路需优先保证短句输入的承接成功率与响应流畅度。

8.3 自然口语表达场景

用户以自然口语方式与 Loona 交流，而非严格按照命令式表达发起输入。

此类场景要求：

- 对于短时间内出现的同轮补充输入，系统可继续承接并合并处理；
- ASR 对非结构化表达需具备基本鲁棒性；
- TTS 回复需自然，不应显得过于机械或模板化。

8.4 播报过程中用户打断与恢复场景

Loona 正在播报或响应过程中，用户再次开口，系统判定需要中断当前播报并重新进入新一轮语音承接；或出现用户误打断、系统误判打断后，Loona 需恢复原有播报。

此类场景要求：

- 播报过程中的重新开口可触发当前播报停止；
- 同时系统较快转入新的语音承接状态；
- 对误打断或误判打断，系统应支持继续原有播报；
- 恢复播报需尽量自然，不产生明显“断裂后重启”的体验；
- 恢复播报不要求逐字从断点续播，但需保证语义连续、用户可理解。

8.5 异常场景

包括误唤醒、识别为空、识别结果异常、网络异常、接口失败、播报异常等情况。

此类场景要求：

- 系统不应无响应或直接沉默；
- 系统状态不应混乱或反复跳变；
- 各类异常需有基础收口方式；

- 异常处理仅覆盖语音交互链路本身，不延伸至决策机侧的复杂任务逻辑。

9. 非功能需求

9.1 性能要求

1. 系统需保持持续语音监听能力，包括播报回复时，不应以“唤醒后再开始监听”作为主链路；
2. 识别到有效唤醒意图后进入当前轮语音承接状态，应有效承接唤醒钱用户内容避免首句被吞或前段音频截断；
3. ASR 处理时延目标应低于 **200ms**；
4. TTS 端到端播报启动时延目标应控制在 **1 秒以内**；
5. 播报被打断后，系统需较快停止当前播报并重新进入输入承接流程；

9.2 稳定性要求

1. 唤醒、判停、ASR、TTS 及播报打断恢复链路需具备稳定运行能力；
2. 网络波动、第三方接口失败、低置信度识别等场景下需具备基础降级策略；
3. 音频流切换过程中不得频繁出现首尾截断、重复播报、异常中断或状态错乱；
4. 判停后语音有效性过滤机制需重点控制误判风险，避免将真实输入错误丢弃；
5. 因判停后有效性过滤误判导致的有效内容丢失率应控制在 **3% 以内**；
6. 播报打断与恢复能力需可复现、可测试、可验证。

10. 验收标准

10.1 通用验收标准

满足以下条件可视为模块基础验收通过：

10.1.1 唤醒

- 系统可稳定识别用户有效唤醒意图，并进入当前轮语音承接状态；
- 唤醒与正文衔接自然，不频繁出现首句被吞或前段音频截断；
- 误唤醒、唤不醒问题得到基础控制，不影响核心使用体验。

10.1.2 判停

- 系统可在用户自然说完后完成判停，并进入解析状态；
- 判停后用户能明显感知系统已结束收音、正在处理，无需继续讲话；
- 判停对短句、自然停顿、连续口语表达具备基础可用性；

- 对同一轮短时间补充输入，可按规则继续承接并合并处理。

10.1.3 ASR

- ASR 可稳定输出供后续链路使用的文本结果；
- 识别准确率满足当前阶段可用要求；
- 对短句、自然口语、多语言夹杂、专有名词等重点场景具备基础可用性；
- 低置信度、识别为空、识别异常、网络异常、超时等情况具备明确基础收口，不出现流程卡死。

10.1.4 TTS

- TTS 可稳定完成语音播报；
- 播报内容与返回文本语义保持一致；
- TTS 可与 Loona 的表情、动作进行基础同步播放；
- 整体表达符合 Loona 的角色感，且不过度打扰用户。

10.1.5 播报打断与恢复

- 用户可在播报过程中重新开口并打断当前播报；
- 打断后系统可重新进入语音承接流程；
- 对用户误打断或系统误判打断场景，Loona 可进行合理恢复播报；
- 恢复播报整体自然、连续、可理解，不出现明显状态混乱。

10.2 当前阶段验收重点

持续关注各子模块重点问题关注。

11. 风险点与待补充项

11.1 当前主要风险点

1. 多模态意图判断若过于激进，可能带来更多误触发问题；
2. 判停后语音有效性过滤机制若误判过高，可能直接造成真实内容丢失；
3. ASR 短句场景下的固定高频词偏置问题，可能持续影响核心体验；
4. 多语言夹杂和专有名词场景下，ASR 稳定性不足可能导致理解链路失真；
5. TTS 情感化表达若与文本、表情、动作不同步，会放大违和感；
6. 播报打断与恢复能力若边界不清，容易与决策机模块的完整打断机制产生职责混淆。

11.2 待补充的实现方案项

以下内容建议后续补充专项技术方案文档：

唤醒判停：

- 多模态无唤醒词意图判断的触发条件与边界规则；
- 判停后语音有效性过滤机制的判断规则、误判控制策略与验收方法；

ASR：

- ASR 候选 API 评估框架、测试方法与选型标准；
- 自研 ASR 模型探索范围、阶段目标与结论输出机制；

TTS：

- TTS 候选方案评估框架及角色音色一致性标准；
- TTS 情绪标签与表情 / 动作映射表；